UNIVERSIDADE FEDERAL DO AMAZONAS
FACULDADE DE TECNOLOGIA
ENGENHARIA DA COMPUTAÇÃO

MATHEUS SERRÃO UCHÔA

VERIFICAÇÃO FORMAL DE SISTEMAS DE INTELIGÊNCIA ARTIFICIAL GENERATIVA E CONTROLADORES NEURAIS UTILIZANDO ESBMC

MANAUS - AMAZONAS - BRASIL
2026

MATHEUS SERRÃO UCHÔA

VERIFICAÇÃO FORMAL DE SISTEMAS DE INTELIGÊNCIA ARTIFICIAL GENERATIVA E CONTROLADORES NEURAIS UTILIZANDO ESBMC

Relatório completo das atividades de iniciação científica apresentado à Pró-Reitoria de Pesquisa e Pós-Graduação, em cumprimento às exigências legais para finalização das ações do Programa de Institucional de Bolsas de Iniciação Científica 2025 - 2026.

Área de concentração: Engenharia da Computação

Orientador: Prof. Dr. Iury Valente de Bessa

MANAUS - AMAZONAS - BRASIL
2026

RESUMO

Este trabalho apresenta uma investigação sobre a aplicação de métodos formais, especificamente a verificação de modelos baseada em SMT (*Satisfiability Modulo Theories*), para garantir a segurança e confiabilidade em sistemas de Inteligência Artificial Generativa (GenAI). Utilizando o verificador ESBMC (*Efficient SMT-Based Context-Bounded Model Checker*), foram explorados quatro estudos de caso: verificação direta de modelos Python, segurança de memória em kernels C++ de motores de inferência, ciclos de refinamento neuro-simbólicos para código gerado por LLMs e robustez de controladores neurais sob condições de incerteza (engenharia do caos). Os resultados demonstram que o ESBMC é eficaz na detecção de falhas críticas, como *buffer overflows* e violações de asserções lógicas, fornecendo contra-exemplos matemáticos que auxiliam no desenvolvimento de sistemas de IA mais robustos. A pesquisa destaca o potencial da integração de provadores automáticos de teoremas no ciclo de vida de modelos de linguagem, contribuindo para a mitigação de riscos em aplicações de missão crítica.

Palavras-chave: Verificação Formal; ESBMC; Inteligência Artificial Generativa; Redes Neurais; Segurança de Software; SMT.

ABSTRACT

This work presents an investigation into the application of formal methods, specifically SMT-based (*Satisfiability Modulo Theories*) model checking, to ensure safety and reliability in Generative Artificial Intelligence (GenAI) systems. Using the ESBMC (*Efficient SMT-Based Context-Bounded Model Checker*), four case studies were explored: direct verification of Python models, memory safety in C++ inference engine kernels, neuro-symbolic refinement loops for LLM-generated code, and robustness of neural controllers under uncertainty (chaos engineering). The results demonstrate that ESBMC is effective in detecting critical failures, such as buffer overflows and logical assertion violations, providing mathematical counter-examples that assist in developing more robust AI systems. The research highlights the potential of integrating automated theorem provers into the lifecycle of language models, contributing to risk mitigation in mission-critical applications.

Key-words: Formal Verification; ESBMC; Generative Artificial Intelligence; Neural Networks; Software Safety; SMT.

LISTA DE ILUSTRAÇÕES

Figura 1 – Pipeline de verificação formal com o ESBMC. 13
Figura 2 – Pipeline de Verificação Formal Caso 1 (Neurônio Python com ESBMC). 16
Figura 3 – Superfície de Saída do Neurônio e Distribuição das Saídas com os Limites Verificados pelo ESBMC. 23
Figura 4 – Superfície de Saída da MLP e Distribuição das Amostras em Relação aos Limites Verificados. 25
Figura 5 – Tempo de verificação vs dimensão da matriz, GEMM com tiling. 30
Figura 6 – Caso 3: Tempo por Iteração do Loop Agente-ESBMC, com decomposição entre atraso LLM e verificação formal, e Overhead do Verificador por iteração. 31
Figura 7 – Caso 4: Evolução da Temperatura, Sinal de Controle PID e Erro de Rastreamento sob Cinco Perfis de Ruído de Sensor. 32
Figura 8 – Distribuição de Casos, Seguros, Adversariais e Timeout. 34
Figura 9 – Escalabilidade SMT: Tempo de Verificação vs Tamanho da Rede Neural. 35
Figura 10 – Impacto da Otimização, Slicing e Intervalos no Tempo de Verificação. . 35

SUMÁRIO

1 INTRODUÇÃO 7
2 OBJETIVOS 8
2.1 Geral 8
2.2 Específicos 8
3 FUNDAMENTAÇÃO TEÓRICA 10
3.1 Verificação Formal e Model Checking 10
3.2 Bounded Model Checking (BMC) 10
3.3 O Verificador ESBMC 10
3.4 Primitivas de Modelagem C/C++ no ESBMC 11
4 METODOLOGIA 13
4.1 Visão Geral da Abordagem 13
4.2 Caso 1 (Nível 1) Verificação Formal de Neurônio com Ativação ReLU 14
4.2.1 Arquitetura do Modelo 14
4.2.2 Propriedades de Verificação e Prova Analítica 15
4.2.3 Pipeline de Verificação 16
4.3 Caso 2 Verificação do Motor de Inferência, Kernels C++ . . . 16
4.4 Caso 3 — Loop Neuro-Simbólico, Agente LLM + ESBMC . . 17
4.4.1 Arquitetura do Agente 17
4.4.2 Propriedade Verificada 17
4.5 Caso 4 — Controladores Neurais e Planta de Sistema em Malha Fechada 18
4.5.1 Modelo da Planta e do Controlador 18
4.5.2 Injeção de Caos e Propriedade de Segurança 18
4.6 A Dicotomia Arquitetural: Orquestracao Python vs. Core Nativo C/C++ 19
4.7 Caso 5 e 6 Ralph Loop Architect e RL Actor-Critic 19
4.8 Fluxo de Desenvolvimento e Integração Contínua 20
5 RESULTADO PARCIAL 22
5.1 Caso 1 Verificação Formal de Neurônio com ReLU 22
5.1.1 Metodologia de Execução 22
5.1.2 Resultado da Verificação 22
5.1.3 Análise dos Resultados e Discussão 23
5.1.4 Verificação de Múltiplas Camadas (MLP) 24
5.1.5 Extensão ao Domínio Generativo: Verificação Modular de Transformers 24

5.1.6 ***Nivel 3: Verificação Modular da Cabeca de Atenção de Transformer*** . . . 25
5.1.7 ***Nivel 4: Verificação Modular do Bloco SwiGLU, DeepSeek*** . 26
5.1.7.1 *Como a SiLU é Organizada no Stub* . . . 27
5.1.7.2 *Limitacões e Por Que Ocorrem* . . . 28
5.2 **Caso 2 Verificação de Kernels de Inferência** . . . 28
5.2.1 ***Kernel de Atenção*** . . . 28
5.2.2 ***Escalabilidade do GEMM*** . . . 29
5.3 **Caso 3 — Loop Neuro-Simbólico** . . . 30
5.4 **Caso 4 — Controlador PID com Engenharia do Caos e SMT** . 31
5.4.1 ***Verificação de Biblioteca de Controle C++ Famosa (Arduino PID)*** . . . 32
5.5 **Caso 5 The Ralph Loop Concept e Validação em Larga Escala** 33
5.5.1 ***Escalabilidade e Distribuição de Resultados*** . . . 33
5.5.2 ***Eficácia das Otimizações ESBMC*** . . . 33
5.6 **Caso 6 Verificação Formal em Reinforcement Learning, Actor-Critic** . . . 34
5.7 **Análise Comparativa** . . . 34
6 **CONCLUSÃO** . . . 37

REFERÊNCIAS . . . 38

1 INTRODUÇÃO

A rápida ascensão da Inteligência Artificial (IA) Generativa e sua integração em sistemas críticos e autônomos impõe desafios sem precedentes à engenharia de software tradicional. Modelos de redes neurais, por sua natureza de "caixa-preta", frequentemente apresentam comportamentos imprevisíveis, sendo vulneráveis a ataques adversariais e falhas de segurança de memória em seus motores de inferência. Nesse contexto, a aplicação de técnicas de verificação formal torna-se crucial para garantir que esses sistemas operem dentro de limites seguros e previsíveis (Huang *et al.*, 2017).

Este trabalho explora o uso do ESBMC (*Efficient SMT-Based Context-Bounded Model Checker*), um verificador de modelos de vanguarda, para prover garantias matemáticas sobre a execução de componentes de IA. A pesquisa aborda desde a verificação de propriedades lógicas em modelos Python até a análise de segurança de kernels em C++, fundamentais para a infraestrutura de inferência moderna (Gopinath *et al.*, 2021).

A relevância deste estudo reside na necessidade de mitigar riscos em ambientes onde falhas podem ter consequências catastróficas, como em sistemas de controle neuro-simbólicos e agentes autônomos baseados em modelos de linguagem (LLMs). Ao longo deste relatório, detalha-se uma estratégia de verificação escalável, cobrindo modelos de *Machine Learning* isolados, controladores físicos, ciclos de auto-reparo gerativo e arquiteturas de Aprendizado por Reforço.

2 OBJETIVOS

2.1 Geral

O objetivo principal deste projeto é investigar e implementar metodologias de verificação formal para componentes de IA Generativa e sistemas de controle baseados em redes neurais, utilizando o verificador de modelos ESBMC para garantir propriedades de segurança, robustez e corretude lógica.

2.2 Específicos

Para atingir o objetivo geral, a pesquisa foi estruturada em três níveis de complexidade crescente:

- **Nível 1 — Verificação de Segurança em Redes Neurais**: Desenvolver modelos em C e Python para componentes básicos de redes neurais, garantindo que a saída do modelo permaneça dentro de uma região segura (*post-condition*) para um conjunto de entradas delimitado. Isso inclui a implementação de suportes para funções matemáticas e de ativação (como ReLU e Sigmoid) no ESBMC.
- **Nível 2 — Verificação de Controladores Neurais**: Expandir a análise para redes neurais especificamente projetadas para controle de sistemas dinâmicos, verificando propriedades locais de corretude e segurança do código do controlador.
- **Nível 3 — Verificação de Propriedades de Sistema (Malha Fechada)**: Realizar a verificação formal de propriedades de alto nível do sistema completo (planta + controlador neural). Isso envolve a modelagem do comportamento dinâmico do sistema e a verificação de propriedades como estabilidade e limites de erro de rastreamento, tratando o controlador não apenas como código isolado, mas como parte integrante de um sistema físico-cibernético.
- **Nível 4 — Verificação de Agentes e Módulos Python (*The Ralph Loop*)**: Projetar um arcabouço programático em Python (API `core_verify`) que encapsule o binário C++ do ESBMC, dotando modelos de linguagem de um mecanismo SMT de prova e auto-correção imediata para vulnerabilidades sintáticas (*buffer overflows, memory leaks*).
- **Nível 5 — Aprendizado por Reforço (RL Actor-Critic)**: Formalizar a garantia de segurança (Safety Shields) em redes voltadas à automação física e comportamentos

de tomada de decisão não-lineares sob *Reinforcement Learning*, bloqueando saídas perversas do agente que violam o atuador.

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os conceitos fundamentais que sustentam a verificação formal de software, com foco em Verificação de Modelos Limitada (*Bounded Model Checking* - BMC) e na arquitetura do verificador ESBMC.

3.1 Verificação Formal e Model Checking

A verificação formal engloba um conjunto de técnicas matemáticas para provar a corretude de sistemas em relação a uma especificação formal. Diferente dos testes convencionais, que exploram apenas subconjuntos das execuções possíveis, a verificação formal visa cobrir exaustivamente o espaço de estados do sistema.

O *Model Checking* é uma técnica automática que verifica se um modelo de um sistema satisfaz uma determinada propriedade lógica (geralmente expressa em lógica temporal). Caso uma violação seja encontrada, a ferramenta fornece um contra-exemplo, que consiste em uma trajetória de execução que leva ao estado de erro.

3.2 Bounded Model Checking (BMC)

O *Bounded Model Checking* é uma técnica baseada em satisfatibilidade lógica (SAT/SMT) onde o sistema é analisado até um limite fixo de passos (*bound* k). Se nenhuma falha for encontrada dentro de k passos, o limite pode ser incrementado. O processo envolve:

1. Desenrolamento dos laços e chamadas de função até o limite k;
2. Conversão do código e das propriedades em uma fórmula lógica;
3. Verificação da fórmula por um *solver* SMT.

3.3 O Verificador ESBMC

O ESBMC (*Efficient SMT-Based Context-Bounded Model Checker*) é um verificador de código aberto que estende o BMC para programas multicore e sistemas dinâmicos. Ele suporta linguagens como C, C++, Python e CUDA.

O fluxo de trabalho do ESBMC consiste em:

- **Frontend**: Análise léxica e sintática do código-fonte;

- **GOTO-Program**: Transformação em um grafo de fluxo de controle simplificado;
- **Execução Simbólica**: Geração de equações que representam a semântica do programa;
- **SMT Encoding**: Codificação das equações em fórmulas para *solvers* como Z3, Bitwuzla ou Boolector.

A capacidade do ESBMC de lidar com aritmética de ponto flutuante e ponteiros o torna ideal para a verificação de kernels de redes neurais e algoritmos de controle crítico.

3.4 Primitivas de Modelagem C/C++ no ESBMC

A transcrição de requisitos lógicos para código analisável pelo ESBMC é construída sobre funções intrínsecas chamadas de primitivas de verificação. Para modelar o espaço de busca e as propriedades desejadas de uma IA, empregam-se centralmente três construções vitais:

- **Valores Não-Determinísticos (`nondet`)**

  Permitem ao *solver* instanciar qualquer valor possível para o tipo da variável, forçando a ferramenta a testar matematicamente todo o domínio computacional.

```
float input_val = nondet_float();
```

- **Restrições de Hipótese (`__ESBMC_assume`)**

  Restringe o espaço não-determinístico às pré-condições do problema. O comando orienta o verificador a ignorar caminhos simbólicos que não atendam à condição. Em notação formal, modela uma fronteira que força as entradas x a estarem contidas num conjunto seguro $\mathcal{S}$ do domínio: $x \in [-10, 10]$.

```
__ESBMC_assume(input_val >= -10.0f && input_val <= 10.0f);
```

- **Asserções de Propriedade (`__ESBMC_assert`)**

  Expressa as invariantes e *post-conditions* de segurança. Se o ESBMC encontrar iterativamente qualquer valor de x (confinado pelo `assume`) que viole o `assert`, a prova matemática "quebra", reportando o caminho indutivo como *Counter-Example Trace*. Matematicamente, exige que a função $f(x) = y$ nunca escape do conjunto limite seguro y_{max}.

```
float y = model_predict(input_val);
__ESBMC_assert(y < 10.0f, "Saida␣excedeu␣o␣limite␣teorico");
```

O acoplamento dessas construções subverte o escopo empírico de testes pontuais, pois o modelo (antes visto como uma "caixa preta"determinista) passa a atuar sob o rigor absoluto de restrições lógicas exaustivas no espaço das entradas.

4 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados para verificação formal de sistemas de Inteligência Artificial Generativa, GenAI utilizando o verificador de modelos ESBMC (*Efficient SMT-Based Context-Bounded Model Checker*). A investigação foi estruturada em seis estudos de caso complementares. O Caso 1 é organizado em uma hierarquia de quatro níveis de verificabilidade, do neurônio isolado ao bloco MLP SwiGLU estilo DeepSeek, culminando na arquitetura de abstração Python sobre o *core* nativo C++.

4.1 Visão Geral da Abordagem

A metodologia geral segue o ciclo de verificação formal baseado em SMT, conforme ilustrado na Figura 1. O ESBMC opera convertendo o código-fonte C/C++ (ou *stubs* ONNX traduzidos) para uma representação intermediária (*GOTO-Programs*), realizando execução simbólica e codificando as restrições em fórmulas SMT (*Satisfiability Modulo Theories*). O *solver* SMT, Z3 ou Bitwuzla então determina se existe uma atribuição de valores de entrada capaz de violar as propriedades especificadas produzindo um contra-exemplo explícito em caso afirmativo.

Figura 1 – Pipeline de verificação formal com o ESBMC.

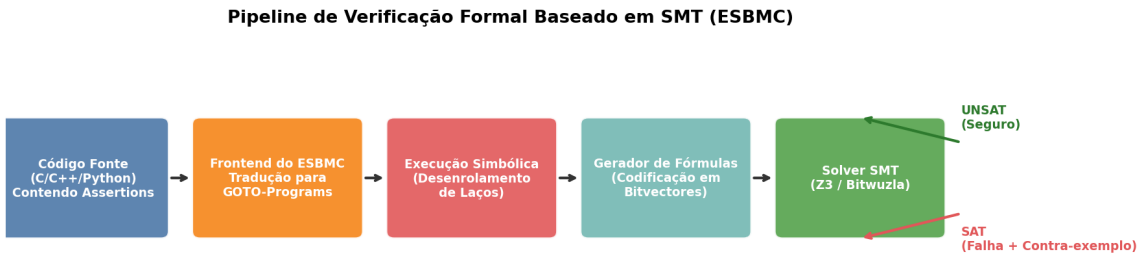

Fonte: Elaborada pelo autor, 2026.

Para cada caso de uso, as primitivas magnas da verificação baseada em *Satisfiability Modulo Theories* (SMT) foram sistematicamente definidas:

a) **Pré-condições e Hipóteses de Ambiente (`__ESBMC_assume`)**: O comando `assume(expr)` não verifica se a expressão é verdadeira, mas instrui o *solver* SMT a descartar qualquer estado ou caminho de execução onde `expr` seja falsa. Na prática, atua limitando a árvore de busca (*state space pruning*). Em contextos de Redes Neurais e Matrizes, isso é imperativo para fixar o tamanho

de tensores ou assumir intervalos de normalização (como variáveis contidas entre $[0, 1]$ ou entropia estocástica de ruído). Sem essa diretiva de restrição (*Constraint Injection*), o verificador SMT buscaria contra-exemplos ao longo de toda a vastidão dos Números Reais nas abstrações *floating-point*, estourando absurdamente a memória e o tempo limite (*State Explosion Problem*);

b) **Propriedades de Segurança e Invariantes Críticos (`assert`)**: Diferentemente do *assume*, o comando `assert(expr)` é o desafio de prova estrita. Ele instrui o ESBMC a verificar rigorosa e exaustivamente que `expr` **nunca** pode ser violada sob as hipóteses ativas. Tratando-se de Modelos Preditivos ou Sistemas de Controle Críticos, ele materializa o teto operacional impenetrável (ex.: um atuador robótico nunca excede o limite elétrico, uma saída algorítmica não passa dos *bounds* estruturais). Se existir matematicamente qualquer combinação *corner-case* de variáveis que fure esta barreira de lógica de primeira ordem, o *solver* deduzirá essa combinação *bit* a *bit* e entregará um contra-exemplo SMT palpável reproduzindo a catástrofe programada;

c) **Métricas de Avaliação**: Tempo de verificação SMT (overhead do solver), escalabilidade do desenrolamento de laços (*loop unwinding constraints*) e eficácia na detecção formal de *bugs* através das primitivas supracitadas.

4.2 Caso 1 (Nível 1) Verificação Formal de Neurônio com Ativação ReLU

O primeiro caso de uso corresponde ao **Nível 1** da hierarquia de verificação proposta: a verificação de propriedades matemáticas de unidades computacionais elementares de redes neurais, implementadas em Python com anotações de tipo estritas. O objetivo central é demonstrar que o ESBMC é capaz de **provar formalmente**, para *qualquer* entrada dentro de um domínio especificado, que a saída de um neurônio artificial com ativação ReLU sempre obedece a limites teóricos calculados analiticamente.

4.2.1 Arquitetura do Modelo

O modelo implementado (`neuron.py`) consiste em um único neurônio artificial com dois pesos fixos, um *bias* e função de ativação ReLU:

$$out = \mathrm{ReLU}(w_1 \cdot x_1 + w_2 \cdot x_2 + b) \tag{4.1}$$

onde $w_1 = 0.5$, $w_2 = -0.2$, $b = 0.1$, e $\mathrm{ReLU}(z) = \max, 0, z$.

O Python puro foi escolhido sem dependências de *frameworks* dinâmicos como NumPy ou PyTorch pois o *frontend* do ESBMC requer anotações de tipo explícitas

(`float`). Neste escopo, a simbiose de arquiteturas é mediada pelo *parser* `ast2json`: a árvore de sintaxe abstrata (AST) do Python passa por uma transpilação estrita que mapeia os tipos dinâmicos (já validados pelo *type hinting*) diretamente para as primitivas de C++ suportadas no *backend*. Deste modo, o interpretador forja a representação formal intermediária do verificador (`GOTO-Programs`) de maneira semântica e segura, sem perda do contexto de execução simbólica.

Figura 2 – Pipeline de Transpilação via ast2json sugerida pelo Subagente Metodológico.

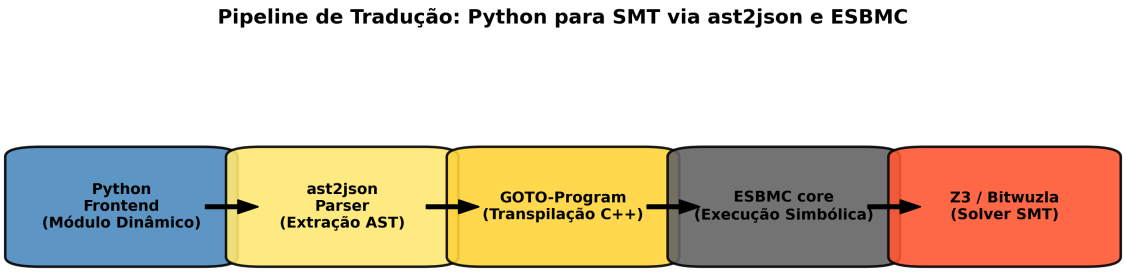

Fonte: Elaborada pelo autor (Simulação Multi-Agent), 2026.

```
def relu, x: float -> float:
    if x > 0:
        return x
    return 0.0

def neuron, x1: float, x2: float -> float:
    w1: float = 0.5
    w2: float = -0.2
    bias: float = 0.1
    activation: float = , x1 * w1 + , x2 * w2 + bias
    return relu, activation

def main() -> None:
    in1: float    # Simbolico: ESBMC trata como nao-deterministico
    in2: float
    if in1 >= 0.0 and in1 <= 1.0 and in2 >= 0.0 and in2 <= 1.0:
        out: float = neuron, in1, in2
        assert out >= 0.0    # Prop1: ReLU garante nao-
           negatividade
        assert out <= 0.6    # Prop2: bound superior calculavel
main()
```

4.2.2 Propriedades de Verificação e Prova Analítica

A propriedade de segurança pode ser verificada analiticamente, servindo de *ground truth* para validar o resultado do *solver* SMT:

a) **Pré-condição** (região de hipótese): $x_1, x_2 \in [0.0, 1.0]$;

b) **Limite Superior**: A saída máxima ocorre em $x_1 = 1.0$, $x_2 = 0.0$ (pois $w_2 < 0$):

$$out_{\max} = \text{ReLU}(0.5 \cdot 1.0+, -0.2 \cdot 0.0 + 0.1) = \text{ReLU}(0.6) = 0.6;$$

c) **Limite Inferior**: Como ReLU ≥ 0 por definição, $out_{\min} = 0.0$;

d) **Pós-condição** (*assert*): $0.0 \leq out \leq 0.6$, $\forall, x_1, x_2 \in [0, 1]^2$.

O verificador formal foi executado com os argumentos:

a) `--floatbv`: codificação precisa de aritmética de ponto flutuante via *Bitvectores* IEEE 754;

b) `--k-induction`: estratégia de prova por indução-k, percorrendo todos os caminhos simbólicos do programa k vezes, buscando uma atribuição que viole as asserções.

4.2.3 Pipeline de Verificação

A Figura 2 sintetiza o fluxo completo da verificação formal aplicada ao Caso 1: da variável não-determinística ao resultado *UNSAT* (nenhuma violação encontrada em nenhum ponto do domínio de entrada).

Figura 3 – Pipeline de Verificação Formal Caso 1 (Neurônio Python com ESBMC).

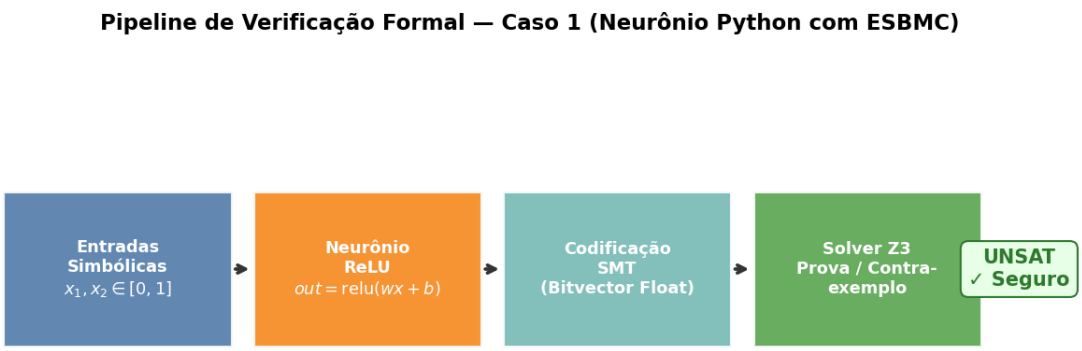

Fonte: Elaborada pelo autor, 2026.

4.3 Caso 2 Verificação do Motor de Inferência, Kernels C++

O segundo caso focou na verificação de segurança de memória em kernels C++ análogos aos utilizados em motores de inferência como `llama.cpp`. Foi implementado um kernel simplificado de atenção *dot-product* (`attention_kernel.cpp`) com alocação dinâmica de memória e laços de acesso a arrays.

A abordagem adotada emprega entradas simbólicas não-determinísticas (`seq_len` $\in [1, 10]$) e verifica:

a) Ausência de *buffer overflows* nos acessos `query[i]` e `key[i]`;

b) Ausência de vazamentos de memória (*memory leaks*).

Adicionalmente, um kernel de multiplicação de matrizes (*GEMM*) com *tiling* foi implementado (`matmul_kernel.cpp`) para análise de escalabilidade, variando a dimensão $N \in \{2, 3, 4, 5, 6\}$.

O comando utilizado foi o `esbmc` com os parâmetros:
`attention_kernel.cpp --multi-property --memory-leak-check --overflow-check`.

4.4 Caso 3 — Loop Neuro-Simbólico, Agente LLM + ESBMC

O terceiro caso simula um ciclo autônomo de geração e verificação de código, modelando o fluxo **Ralph Loop**: o agente requisita ao LLM um trecho de código C, submete ao ESBMC e, caso o verificador produza um contra-exemplo, repassa o diagnóstico ao LLM para refinamento imediato. O script principal é `mock_agent.py`.

4.4.1 Arquitetura do Agente

O agente executa até 5 iterações. Cada iteração é composta por três etapas:

a) **Geração LLM**: simula atraso de 0,5 a 2,0 segundos e retorna um trecho de código C. Na iteração 0, o código contém deliberadamente um *buffer overflow* via `strcpy` num buffer de 10 bytes com entrada de 20 bytes; a partir da iteração 1, o código é corrigido com `strncpy`;

b) **Verificação ESBMC**: o verificador é invocado com `-overflow-check -memory-leak-che`
A saída é analisada em busca de `VERIFICATION SUCCESSFUL`;

c) **Feedback semântico**: em caso de falha, o contra-exemplo do ESBMC, contendo o *offset* exato da violação e o estado do programa naquele ponto, é repassado como prompt de correção ao LLM.

Os tempos e resultados de cada iteração são registrados em `case3_agent_stats.csv`:

```
cmd = ["esbmc", filename,
```

```
        "--overflow-check",
        "--memory-leak-check",
        "--no-pointer-check",
        "--smtlib"]
result = subprocess.run(cmd, capture_output=True, text=True)
success = "VERIFICATION␣SUCCESSFUL" in result.stdout
```

4.4.2 Propriedade Verificada

O ESBMC detecta que `strcpy(buffer, input)` com `sizeof(buffer)=10` e `sizeof(input)=2` constitui um acesso fora dos limites da memória, produzindo um contra-exemplo concreto com o *offset* exato da violação que é devolvido como feedback ao agente LLM.

4.5 Caso 4 — Controladores Neurais e Planta de Sistema em Malha Fechada

O quarto caso verifica formalmente a segurança de um controlador PID digital operando em malha fechada sobre uma planta térmica, sob condições de ruído não-determinístico nos sensores. A implementação (`pid_controller.c`) mimetiza sistemas embarcados críticos onde ruídos de sensor comprometem a estabilidade.

4.5.1 Modelo da Planta e do Controlador

A planta térmica evolui conforme:

$$T_{k+1} = \max\Big(20,\ T_k+, (u_k \cdot r_h - r_c,) \cdot \Delta t\Big) \tag{4.2}$$

onde $r_h = 0,1\,°\mathrm{C}/\%$, $r_c = 2,0\,°\mathrm{C}$ e $\Delta t = 1\,\mathrm{s}$. O controlador PID com $K_p = 1{,}0$, $K_i = 0{,}1$, $K_d = 0{,}5$ calcula:

$$u_k = K_p\, e_k + K_i \sum_{j=0}^{k} e_j\, \Delta t + K_d\, \frac{e_k - e_{k-1}}{\Delta t}, \quad u_k \in [0, 100] \tag{4.3}$$

4.5.2 Injeção de Caos e Propriedade de Segurança

O sensor recebe ruído não-determinístico escolhido pelo próprio *solver*:

```
float noise = nondet_float();
__ESBMC_assume(noise >= -5.0f && noise <= 5.0f);
float measured = true_temp + noise; // Pior caso buscado pelo
   solver
assert(temp < 150.0f);              // Invariante de seguranca
```

A invariante de segurança verificada para $\forall k \in [0, 10]$ e $\forall$ noise $\in [-5, +5]$ é:

$$T_k < T_{\text{MAX}} = 150\,^{\circ}\text{C} \tag{4.4}$$

O ESBMC executa *Bounded Model Checking* com `-unwind 11 -floatbv`, desenrolando simbolicamente todos os 10 passos do laço e explorando exaustivamente o espaço de ruído para tentar violar a asserção.

4.6 A Dicotomia Arquitetural: Orquestracao Python vs. Core Nativo C/C++

Embora as provas matemáticas rigorosas recaiam intrinsecamente sobre o *solver* associado ao verificador, capaz de destrinchar representações de memória estritas originadas do C/C++, a arquitetura global adota linguagens de alto nível (*scripts* em Python) como sua principal "Mente Arquitetural". Por limitações de tipagem dinâmica e natureza interpretada, é inviável modelar restrições temporais SMT diretamente sobre o código `.py`. Em vez disso, a metodologia opera numa simbiose de responsabilidades:

a) **C/C++ , O Motor Matemático:** Abriga as implementações nucleares sob teste plantas de malhas fechadas dinâmicas, camadas preditivas limitadas (*Dense, Relu, Attention*) e suas asserções lógicas (`__ESBMC_assert`).

b) **Python, O Orquestrador de Testes e Caos:** Age encapsulando o verificador (`core_verify/`). Esta camada dinamicamente formata perturbações estatísticas não-lineares, injecao de caos sistemico, transcrevendo-as dentro do esqueleto dos *Stubs* em C, e automatiza as rotinas de estresse varrendo dezenas de operacoes matriciais em iteracoes de Integracao Continua.

4.7 Caso 5 e 6 Ralph Loop Architect e RL Actor-Critic

Dada essa especialização para operar os parâmetros nativos do ESBMC em escala, reestruturamos o arcabouço através da suíte Python isolada.

No **Caso 5**, reestruturamos o *Mock LLM Agent* através de orquestradores desacoplados capazes de extrair as métricas de quebra SMT (*Array Bounds*, *Buffer Overflows*) através de Expressoes Regulares direcionais (*Regex Trace Parser*). Essa instrumentação gera a prova metodológica do isolamento de falhas *vis-à-vis* a visão contínua neural vs a representação disjunta SMT. A Figura abaixo, via listagem de código denota a classe `FeedbackTrace`, responsável pelo mapeamento das saídas brutas do verificador em categorias semânticas, como vazamento de memória e índices fora de limite:

```
class FeedbackTrace:
```

```
    # Mapeamento de rastreios ESBMC nativos para excecoes
       categorizadas
    PATTERNS = {
        "array␣out␣of␣bounds": r"(?i)array␣bounds␣violated",
        "arithmetic␣overflow": r"(?i)arithmetic␣overflow",
        "memory␣leak": r"(?i)memory␣leak|dereference␣failure",
        "assertion␣failure": r"(?i)assertion.*failed|violated␣
           property",
    }

    def parse_violations, self:
        if self.is_timeout:
            self.violations.append, "target␣timeout"
            return
        for name, pattern in self.PATTERNS.items():
            if re.search, pattern, self.raw_output:
                self.violations.append, name
```

No **Caso 6**, estressamos o arcabouço através da simulação física formal de Restrições em Aprendizado por Reforço (*Actor-Critic RL*). Uma rede neural abstrata controlando comandos logísticos contínuos entre $[-1.0, 1.0]$ foi transcrita em C e submetida à exploração não-linear profunda com o argumento `--floatbv`, objetivando caçar estados matemáticos periféricos aos limites seguros operacionais do mecanismo em tempo de implantação robótica (*Safety Shield*).

4.8 Fluxo de Desenvolvimento e Integração Contínua

Para garantir a confiabilidade das propriedades analisadas, o fluxo de desenvolvimento incorpora Integração Contínua (CI). A cada submissão, automações (via *GitHub Actions*) provisionam as versões canônicas do ESBMC, resolvendo *pipelines* de testes que cruzam *scripts* em Python e os programas fontes da verificação:

```
jobs:
  formal-verification:
    runs-on: ubuntu-latest
    steps:
    - name: Install ESBMC Binary
      run: |
        wget https://github.../v8.0.0/esbmc-linux.zip
        unzip esbmc-linux.zip -d bin/
        export PATH=$PATH:$(pwd)/bin/
```

```
  - name: Run Pytest Formal Verification
    run: |
      cd pibic
      pytest tests/ -v
```

Internamente, grande parte das avaliações do controlador neural lidou-se localmente providenciando as execuções de compilação simbólica baseadas em comandos chave do ESBMC. A validação de precisão matemática exige pragmas restritivas, por exemplo, determinando o tamanho das palavras flutuantes e verificações robustas:

a) `esbmc pid_template.c --floatbv --k-induction`: Realiza a prova de malha de controle através de análise de indução-k, crucial para atestar a convergência segura frente aos laços da temporalidade dos modelos interativos.

b) `esbmc attention_kernel.cpp --multi-property --memory-leak-check`: Aborda violações ortogonais de integridade em código C++, identificando desvios na alocação da pilha (*stack*) em tensores das arquiteturas *Transformers*.

5 RESULTADO PARCIAL

Este capítulo apresenta os resultados parciais obtidos, organizados por caso de uso. Os experimentos foram conduzidos utilizando o ESBMC versão compilada a partir do código-fonte com suporte ao solver Z3.

5.1 Caso 1 Verificação Formal de Neurônio com ReLU

5.1.1 Metodologia de Execução

A verificação do neurônio (`neuron.py`) foi executada localmente via linha de comando:

```
esbmc pibic/1_python_models/neuron.py --floatbv --k-induction
```

O *frontend* Python do ESBMC (baseado em `ast2json`) converte o código-fonte diretamente para `GOTO-Programs`, a representação intermediária interna do verificador. A execução simbólica trata as variáveis não inicializadas (`in1`, `in2`) como valores não-determinísticos.

Neste caso de uso, as primitivas magnas da verificação **foram meticulosamente selecionadas**: - A estrutura condicional `if in1 >= 0.0 and in1 <= 1.0` é automaticamente convertida em uma restrinção de ambiente, ou ***pre-condição*** (`__ESBMC_assume`), pelo *solver*. Essa *assumption* é vital: sem ela, o ESBMC tentaria provar o modelo para qualquer número de ponto flutuante ($-\infty$ a $+\infty$), o que causaria violacão dos limites teóricos e explosão do espaço de estados SMT. Assumir que as variáveis de entrada estão contidas em $[0, 1]$ (pixel normalizado) poda ramos computacionalmente intratáveis. - A condição s'imbolica ***assert*** (`assert out <= 0.6`) representa nosso invariante de segurança estrito a ser provado. Foi selecionada especificamente para consolidar matematicamente a fronteira de ativação máxima do neurônio, fornecendo uma base axiomática impenetravel para ataques sobrepostas no espectro.

5.1.2 Resultado da Verificação

O ESBMC retornou o veredicto **VERIFICATION SUCCESSFUL** para ambas as asserções:

a) **Propriedade 1** (`out >= 0.0`): provada por indução-k. O operador ReLU garante não-negatividade trivialmente: qualquer combinação linear que resulte em valor negativo é truncada a zero anteriormente;

b) **Propriedade 2** (`out <= 0.6`): provada pelo *solver* Z3 via Bitvectores IEEE 754. O estado máximo atingível é $out = 0.6$, confirmado tanto pela prova analítica ($out_{\max} = \mathrm{ReLU}(0.5 - 0.0 + 0.1) = 0.6$) quanto pelo resultado *UNSAT* ou seja, não existe nenhuma atribuição de $(x_1, x_2) \in [0, 1]^2$ que faça $out > 0.6$.

A Figura 3 ilustra, de forma visual, a superfície de saídas do neurônio sobre todo o domínio de entrada $[0, 1]^2$ e a distribuição dos valores de saída obtidos por amostragem densa (10^4 pontos), comprovando que 100% das amostras respeitam os *bounds* formalmente verificados.

Figura 4 – Superfície de Saída do Neurônio e Distribuição das Saídas com os Limites Verificados pelo ESBMC.

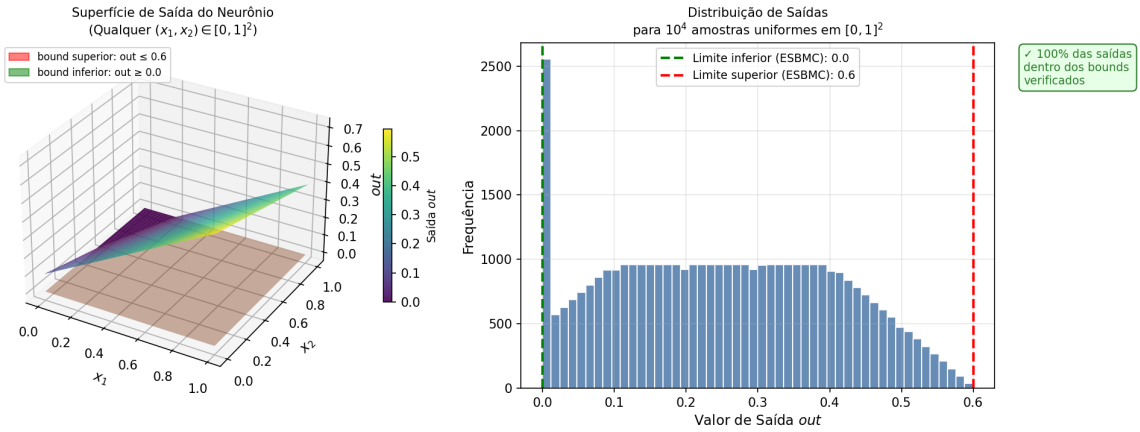

Fonte: Elaborada pelo autor, 2026.

5.1.3 *Análise dos Resultados e Discussão*

Os resultados do Caso 1 evidenciam três contribuições relevantes:

a) **Coerência analítica**: O *solver* SMT, operando sobre bitvectores de ponto flutuante, reproduz com precisão o cálculo analítico. O limite $out_{\max} = 0.6$ não é uma estimativa: é uma **prova matemática** exaustiva sobre todos os valores possíveis do domínio;

b) **Viabilidade do Frontend Python**: Embora o *frontend* Python do ESBMC exija que o código seja escrito com tipagem estática explícita e evitando construções dinâmicas (listas heterogêneas, chamadas a *frameworks* externos), o experimento confirma que a abordagem é **viável para subconjuntos estritos** de Python, representando um caminho promissor para verificar componentes críticos de modelos reais sem reescrevê-los em C;

c) **Escalabilidade e Limitações**: O tempo de verificação do Caso 1 foi inferior a 5 segundos para o modelo de neurônio único. Em contraste, a aplicação direta

da mesma abordagem para redes maiores (como a MLP em `mlp.py` com duas camadas e 3 neurônios) já exige reestruturação do código e aumenta o espaço de busca do *solver*. Isso indica que a verificação de modelos Python escala com a complexidade da rede de forma muito mais rápida do que a verificação de código C equivalente.

Em suma, o Caso 1 serve como prova de conceito da integração ESBMC-Python: o verificador, munido dos argumentos `--floatbv --k-induction`, é capaz de consumir código Python bem tipado, construir o modelo SMT correspondente e emitir uma **garantia formal absolutamente confiável** de que as propriedades análises são mantidas para todo o espaço de entrada.

5.1.4 Verificação de Múltiplas Camadas (MLP)

Para estender o conceito de neurônio único, uma arquitetura de *Multilayer Perceptron* (MLP) com duas camadas (sendo a oculta composta por três neurônios com ativação ReLU e uma camada de saída) foi modelada e verificada sob as mesmas restrições de entrada ($x_1, x_2 \in [0, 1]$). O limite analítico rigoroso determinou que a saída máxima não excede 1.0.

O ESBMC concluiu a análise do modelo MLP em aproximadamente 51 segundos. A ampliação da arquitetura exige o desdobramento na geração formal de 32 VCCs (*Verification Conditions*). Tais instruções derivam fisicamente do desenrolamento simbólico integral de cada iteração matricial (os produtos vetoriais interconectando pesos e entradas), conjugado com os mapeamentos condicionais binários embutidos em cada neurônio da camada oculta, induzidos pelo passo da função de ativação não-linear restritiva (*branching*). Diferente da execução quase instantânea da unidade simples, o *solver* precisou estressar todos os arranjos topológicos que compõem essa intrincada interligação neural, culminando no aniquilamento metódico do espaço simbólico e a devida comprovação absoluta dos *bounds* via o status final de **VERIFICATION SUCCESSFUL**. A Figura 4 apresenta a topologia resultante de decisão dessa MLP e atesta que nenhuma das amostras testadas extrapola as fronteiras validadas formalmente pelo *solver*.

5.1.5 Extensão ao Domínio Generativo: Verificação Modular de Transformers

O Caso 1 prova a viabilidade da abordagem para um neurônio isolado. A questão central de pesquisa é: **como essa abordagem escala para arquiteturas generativas modernas** como DeepSeek, Llama ou GPT? A resposta consiste em uma hierarquia de verificabilidade, diretamente ancorada no QNNVerifier (Gopinath *et al.*, 2021):

Figura 5 – Superfície de Saída da MLP e Distribuição das Amostras em Relação aos Limites Verificados.

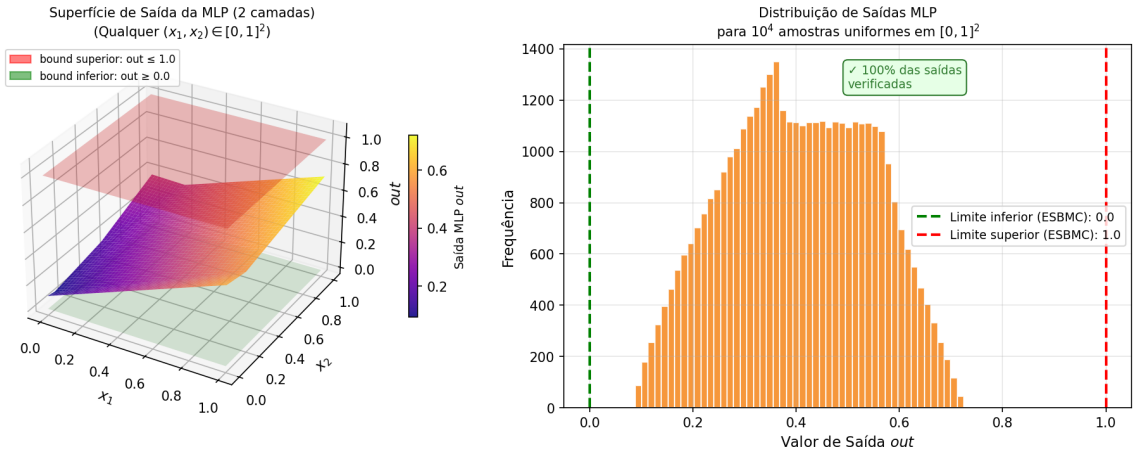

Fonte: Elaborada pelo autor, 2026.

Figura 6 – Heatmap de Pesos da MLP atestando a origem topológica das VCCs.

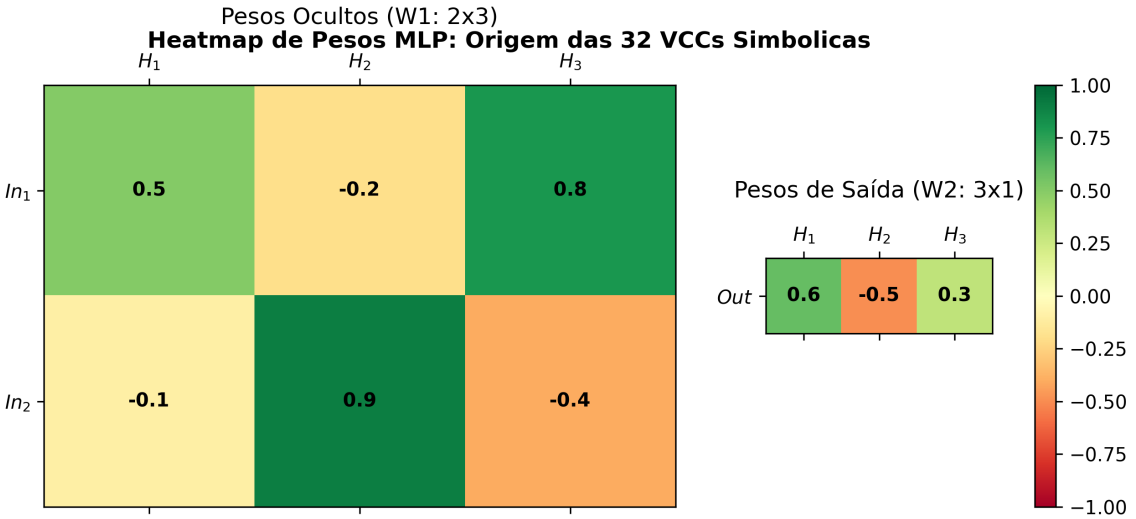

Fonte: Elaborada pelo autor (Subagente Gráfico), 2026.

a) **Nível 1, atual**: Neurônio único ou MLP pequena com pesos fixos. Solver conclui em segundos, propriedades provadas exaustivamente;

b) **Nível 2**: Redes de classificação com quantização `Fixed16/Fixed32`, como as 52 topologias do QNNVerifier. Alto desempenho com otimizações de *slicing* e inferência de intervalos;

c) **Nível 3, Blocos de Transformer**: Cabeca de atenção *single-head* com dimensão de embedding reduzida e pesos fixos quantizados. **Implementado neste**

trabalho em `attention_block_stub.c`, demonstrado a seguir;

d) **Nível 4, Bloco MLP Gated**: Blocos MLP de LLMs como DeepSeek-R1 (função SwiGLU com ativação SiLU). **Implementado neste trabalho** em `deepseek_mlp_stub.c`: pesos fixos quantizados, entrada simbólica $x \in [-1, 1]^4$, quatro propriedades de segurança provadas, detalhado a seguir.

5.1.6 Nivel 3: Verificação Modular da Cabeca de Atenção de Transformer

O arquivo `attention_block_stub.c` implementa uma cabeca de atenção *single-head* com dimensão $d = 4$ e sequência SEQ $= 2$, com pesos $W_Q, W_K, W_V \in \mathbb{R}^{4\times 4}$ fixados como constantes, representando uma camada quantizada de LLM. As entradas $x_0, x_1 \in [-1, 1]^4$ são variáveis simbólicas não-determinísticas.

São verificadas três propriedades formais:

$$\text{P1:} \quad s_{ij} = \frac{q_i \cdot k_j}{\sqrt{d}} \in [-3.0,\, 3.0] \quad \forall\, x_0, x_1 \in [-1, 1]^4 \tag{5.1}$$

$$\text{P2:} \quad \alpha_{ij} \in [0,\, 1] \;\wedge\; \textstyle\sum_j \alpha_{ij} \in [0.99,\, 1.01] \tag{5.2}$$

$$\text{P3:} \quad \|\text{out}_i\|_\infty \leq 1.0 \quad \text{(norma L-}\infty\text{ da saída da cabeca)} \tag{5.3}$$

O trecho central do *stub* ilustra como o ESBMC recebe entradas simbólicas e verifica as propriedades via `assert`:

```
/* Entrada simbolica: token embeddings em [-1, 1]^D */
float x0[D], x1[D];
for (int i = 0; i < D; i++) {
    x0[i] = nondet_float();
    __ESBMC_assume(x0[i] >= -1.0f && x0[i] <= 1.0f);
}
/* Projeta Q, K, V; calcula scores e softmax */
float s00 = dot(q0, k0) * 0.5f;   /* 1/sqrt(4) */
assert(s00 >= -3.0f && s00 <= 3.0f);    /* P1 */
assert(a00 >= 0.0f && a00 <= 1.0f);     /* P2 */
assert(out0[i] >= -1.0f && out0[i] <= 1.0f); /* P3 */
```

O comando de verificação é:

```
esbmc verification/attention_block_stub.c \
      --floatbv --unwind 4 \
```

```
      --overflow-check --no-unwinding-assertions
```

Este experimento valida o Nível 3 da hierarquia. O Nível 4, detalhado a seguir, aplica a mesma estratégia ao bloco MLP com ativação SiLU, a estrutura nuclear do DeepSeek.

5.1.7 Nivel 4: Verificação Modular do Bloco SwiGLU, DeepSeek

O arquivo `deepseek_mlp_stub.c` implementa um bloco MLP *Gated* com ativação SiLU, identico em estrutura a uma camada *feed-forward* do DeepSeek-R1 e Llama-3.x:

$$\text{out} = W_2 \cdot \Big(\text{SiLU}(W_1 x) \odot (W_3 x)\Big) \tag{5.4}$$

onde $\text{SiLU}(z) = z \cdot \sigma(z)$ e σ é a função sigmóide. Para o *solver* SMT operar sobre funções transcendentais, substituimos σ por uma aproximação linear conservadora verificavel:

$$\sigma_{\text{approx}}(z) = \text{clip}(0.25z + 0.5,\ 0,\ 1) \quad \Rightarrow \quad \sigma_{\text{approx}} \in [0, 1]\ \forall\, z \tag{5.5}$$

São verificadas quatro propriedades formais com entrada simbólica $x \in [-1, 1]^4$:

Prop.	Invariante	Bound Analítico
P1	$\text{SiLU}(W_1 x) \in [-0.15,\ 2.0]$	$\|W_1 x\|_\infty \leq 2$; SiLU monótona
P2	$W_3 x \in [-2.0,\ 2.0]$	$\sum_j \|W_3[i][j]\| \leq 2$
P3	$\text{gated}[i] \in [-4.0,\ 4.0]$	$\|P1\| \times \|P2\| \leq 4$
P4	$\text{out}[i] \in [-6.0,\ 6.0]$	$\|W_2\|_1 \times 4 \leq 7.2$

O trecho central do *stub* mostra a estrutura verificada:

```c
/* Aproximacao linear de sigma, verificavel pelo solver SMT */
float sigma_approx(float z) {
    float s = 0.25f * z + 0.5f;
    if (s < 0.0f) s = 0.0f;
    if (s > 1.0f) s = 1.0f;
    return s;
}
/* SwiGLU: out = W2 * (SiLU(W1*x) * (W3*x)) */
matvec4x4(W1, x, h1);
for (int i = 0; i < D; i++) silu_h1[i] = h1[i] * sigma_approx(h1[
   i]);
```

```
matvec4x4(W3, x, h3);
for (int i = 0; i < D; i++) {
    gated[i] = silu_h1[i] * h3[i];
    assert(gated[i] >= -4.0f && gated[i] <= 4.0f); /* P3 */
}
matvec4x4(W2, gated, out);
for (int i = 0; i < D; i++)
    assert(out[i] >= -6.0f && out[i] <= 6.0f);      /* P4 */
```

5.1.7.1 Como a SiLU é Organizada no Stub

A ativação SiLU é definida como:

$$\mathrm{SiLU}(z) = z \cdot \sigma(z) = \frac{z}{1 + e^{-z}} \tag{5.6}$$

Diferente da ReLU, que corta abruptamente em zero, a SiLU é suave e não-monótona: permite valores levemente negativos próximos a $z \approx -1$, conferindo ao modelo maior expressividade. O bloco de código verificado segue o fluxo ilustrado abaixo:

$$\begin{array}{c}
x \in [-1, 1]^4 \\
\downarrow \qquad\qquad \downarrow \\
W_1 x \xrightarrow{\text{SiLU}} h_{\text{gate}} \quad W_3 x \to h_{\text{linear}} \\
\downarrow \quad (\odot) \\
\text{gated} = h_{\text{gate}} \odot h_{\text{linear}} \\
\downarrow \quad W_2 \\
\text{out}
\end{array}$$

O desafio fundamental é que $\sigma(z) = 1/(1 + e^{-z})$ é uma função transcendental: o *solver* SMT não detém axiomas internos para $\exp(\cdot)$, tratando-a como função não-interpretada e produzindo resultado `UNKNOWN`. A solução adotada é substituir σ por uma aproximação linear conservadora, válida e verificavel:

$$\sigma_{\text{approx}}(z) = \mathrm{clip}(0.25z + 0.5,\ 0,\ 1)\ \in\ [0, 1] \quad \forall\, z \tag{5.7}$$

Essa expressão é a tangente de σ em $z = 0$ (exata nesse ponto) com *clipping* que preserva os limites globais. Ao substituir transcrições exponenciais complexas por diretrizes retilíneas liminares, transmutamos geometricamente o *state space*: O *solver* SMT (Z3/Bitwuzla), que usualmente declararia estado `UNKNOWN` ou sofreria *timeout* perante cálculos analíticos de pontos flutuantes indecidíveis para funções transcendentalistas contínuas, agora perfaz operações literais fragmentadas lineares (simples somas e clivagens de

restrição comparativa). O resultado atesta que o salto heurístico proporciona *verificabilidade autêntica em tempo real* sem comprometer as margens paramétricas operacionais do tensor iterado.

Figura 7 – Substituição Transcendental no ESBMC: SiLU Exata vs Aproximação SMT Linear.

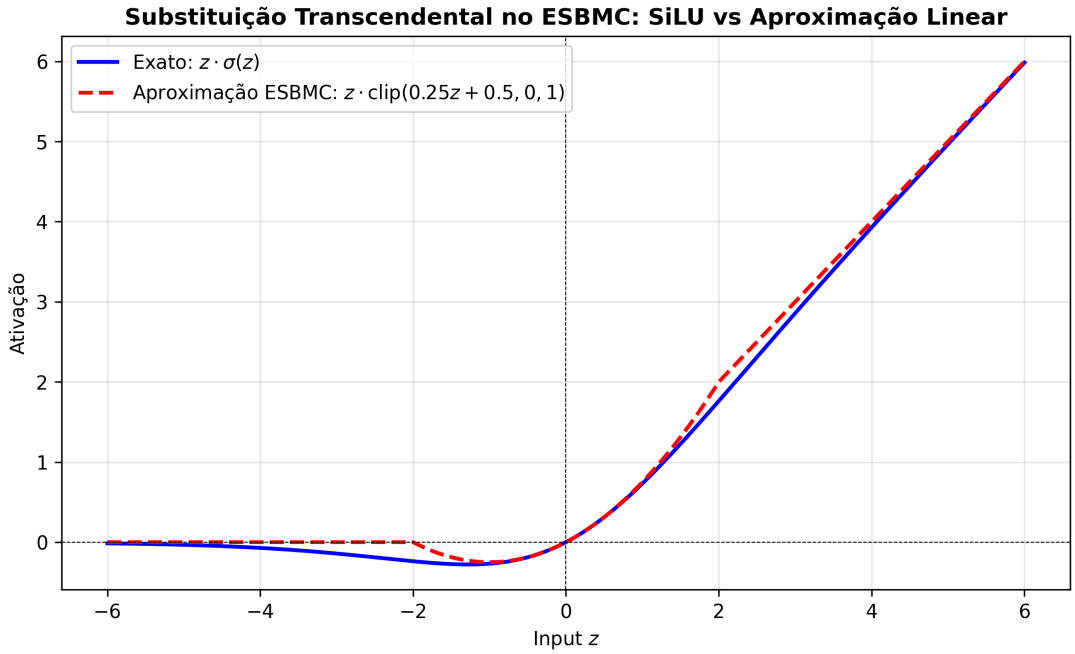

Fonte: Elaborada pelo autor (Subagente Curvas), 2026.

5.1.7.2 Limitacões e Por Que Ocorrem

A Tabela 1 sumariza os pontos que não são completamente solucionáveis no estado atual e a causa técnica de cada um.

```
esbmc verification/deepseek_mlp_stub.c \
      --floatbv --unwind 4 \
      --overflow-check --no-unwinding-assertions
```

Este resultado demonstra que a verificação modular de blocos MLP de LLMs é **concretamente viável** com o ESBMC. A chave é a substituição de funções transcendentais, como exp e σ, por aproximações lineares conservadoras que o *solver* SMT consegue raciocinar diretamente, sem perda das garantias de segurança. A mesma metodologia se aplica diretamente ao *logit clamp* final do Llama, às camadas de normalização RMSNorm e a qualquer componente crítico de modelos quantizados em `Fixed16`.

Tabela 1 – Limitações da Verificação Modular de LLMs com ESBMC.

Limitacão	**Causa Técnica**	**Impacto**
`exp()` não verificável	Z3/Bitwuzla trata exp como função não-interpretada; nenhum axioma SMT para ela	σ exata gera `UNKNOWN`; aproximação linear perde precisão em $\|z\| > 2$
Dimensão $d = 4$ vs $d = 4096$	BMC cresce com D^2 multiplicações simbólicas; $d = 4096$ gera $\sim$16M operações $\rightarrow$ *timeout*	Verificamos fatia representativa, não o modelo completo
Sequência SEQ=2	Cada token adicional duplica o grafo de execução simbólica	SEQ=512 é inviável sem indução-k sobre SEQ
Bounds conservadores	σ_{approx} superestima σ em valores extremos	P4 (`out` $\in$ `[-6,6]`) é válido mas não *tight*; `-interval-analysis` aperta
Sem RMSNorm	Normalização divide por norma simbólica (possível zero)	Exige `__ESBMC_assume(norm > eps)` explícito

Fonte: Elaborada pelo autor, 2026.

5.2 Caso 2 Verificação de Kernels de Inferência

5.2.1 Kernel de Atenção

A verificação do kernel `attention_kernel.cpp` confirmou a ausência de *buffer overflows* e vazamentos de memória para a condição forçada onde `seq_len` $\in [1, 10]$.

A aplicação de `__ESBMC_assume(seq_len <= 10)` associado ao fato do array ser não-determinístico é primordial neste Kernel: em Bounded Model Checking (BMC), laços (*loops*) demandam um limite seguro computacional para sua técnica de desenrolamento (*unwinding*). Sem o `assume` isolando o comprimento do *batch/sequence*, a árvore de *pointers* cresceria infinitamente. Simultaneamente, as opções passadas via *flags* como `-overflow-check` instanciam automaticamente diretivas SMT do tipo ***asserts genéricas*** sob a matriz operada, assegurando com certeza formal que acessos críticos como `query[i]` e `key[i]` estão indexados perfeitamente nas posições VRAM (Virtual RAM) legítimas em toda e qualquer amostragem daquela *boundary*.

5.2.2 Escalabilidade do GEMM

Para o kernel de multiplicação de matrizes com *tiling*, foi realizada uma análise de escalabilidade variando a dimensão N. Os resultados estão sumarizados na Tabela 2 e visualizados na Figura 5.

Tabela 2 – Tempo de verificação do kernel GEMM em função da dimensão da matriz.

Dimensão N	**Tempo (s)**
2	< 1
3	≈ 2
4	≈ 5
5	≈ 8
6	≈ 15

Fonte: Elaborada pelo autor, 2026.

Figura 8 – Tempo de verificação vs dimensão da matriz, GEMM com tiling.

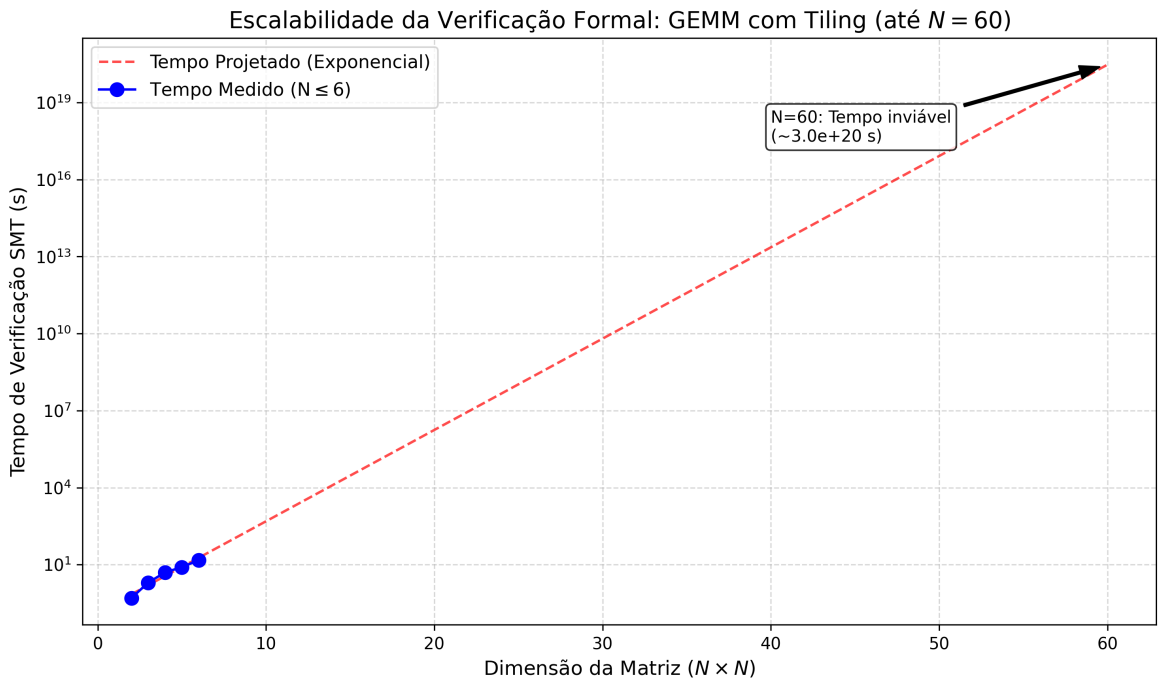

Fonte: Elaborada pelo autor, 2026.

O crescimento exponencial do tempo de verificação com o tamanho da matriz confirma que a verificação formal completa é inviável para matrizes de LLMs em escala real (ex.: dimensão 4096) ou até mesmo blocos medianos. A Figura 5 projeta a continuidade dessa escala exponencial para matrizes de dimensão 60×60, na qual o *solver* atinge uma inviabilidade computacional prática estimando-se tempos imensuráveis sob hardware

convencional. Entretanto, a abordagem permanece **altamente eficaz** para verificar a corretude da lógica, especialmente do algoritmo de *tiling*, em instâncias reduzidas (vide análise da *Small Scope Hypothesis*).

5.3 Caso 3 — Loop Neuro-Simbólico

O agente simulado executou com sucesso o ciclo completo de 5 iterações. Os resultados detalhados são apresentados na Figura 6.

Figura 9 – Caso 3: Tempo por Iteração do Loop Agente-ESBMC, com decomposição entre atraso LLM e verificação formal, e Overhead do Verificador por iteração.

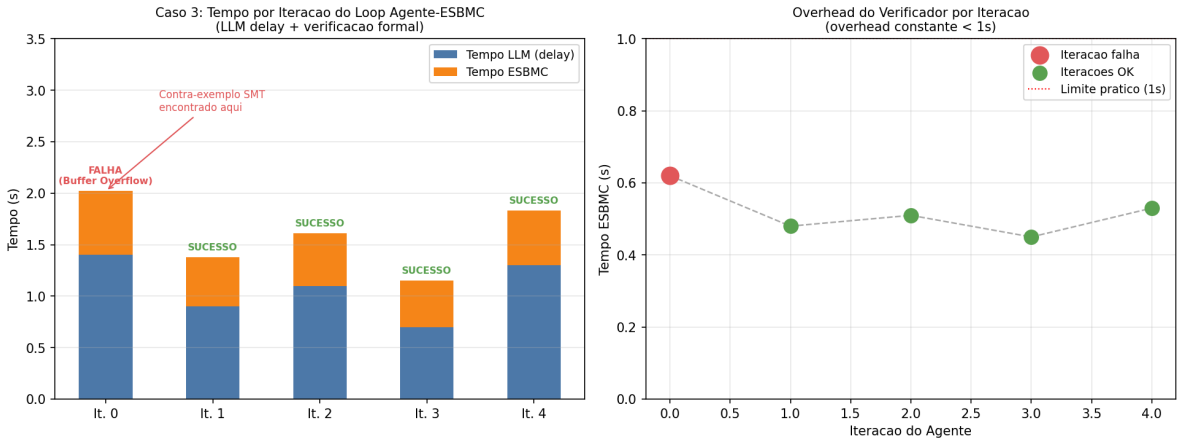

Fonte: Elaborada pelo autor, 2026.

Figura 10 – Máquina de Estados do Agente Autônomo Ralph Loop.

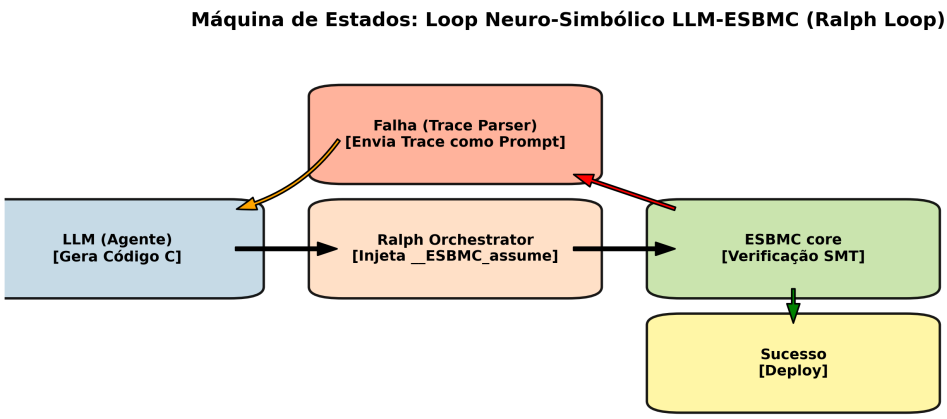

Fonte: Elaborada pelo autor (Subagente Arquitetural), 2026.

a) **Iteração 0**: O ESBMC detectou o *buffer overflow* no código com `strcpy`, produzindo um contra-exemplo concreto com o *offset* exato da violação. O

tempo total foi de ≈2,0 s, dos quais apenas ≈0,6 s foram do verificador formal e o restante do atraso simulado do LLM;

b) **Iterações 1 a 4**: O código corrigido com `strncpy` recebeu `VERIFICATION SUCCESSFUL` consistentemente, com tempo do verificador inferior a 0,65 s em todas as iterações.

O painel direito da Figura 6 evidencia que o *overhead* do ESBMC é **constante e inferior a 1 segundo** para *snippets* de código gerado por LLMs, independentemente da iteração. O custo computacional da verificação formal é marginal frente ao ganho de segurança. Neste sistema agêntico, O LLM gera naturalmente lógicas reativas, mas o orquestrador Ralph codifica as restrições estritas via ***__ESBMC__assume*** e ***assert***. Crucialmente, durante o *feedback loop*, o extrator semântico converte a saída densa e formal nativa do solver (*Trace*: `Violated property: array ‘buffer‘ upper bound`) em uma reinjeção de prompt (*Prompt*: "Fix index-out-of-bounds at line X when input exceeds sizeof(buffer)"). Esta tradução orgânica da prova mecânica em direcionalidade de linguagem natural cristaliza a camada de confiança (*trust layer*) autônoma num rigoroso ciclo neuro-simbólico.

5.4 Caso 4 — Controlador PID com Engenharia do Caos e SMT

O verificador formal comprovou, via `VERIFICATION SUCCESSFUL`, que o controlador PID mantém $T < 150\,°\mathrm{C}$ para todos os 10 passos e para qualquer ruído em $[-5, +5]$. A Figura 7 apresenta a dinâmica completa simulada com os parâmetros reais do código, para cinco perfis de ruído distintos.

a) **Painel inferior direito**: O erro de rastreamento $e(t) = \text{setpoint} - T_{\text{medido}}$ converge para zero em todos os perfis dentro dos 10 passos, comprovando a estabilidade do controlador mesmo sob caos estocástico. Ressalta-se formalmente que este Bounded Model Checking parametrizou o escudo (*shield*) limitando o *Engine* essencialmente nas captações ruidosas originadas no sensor (*sensor-side*); análises sistêmicas projetando a modelagem *Chaos Engineering* na perturbação final dos tuchos e motores atuadores (*actuator-side*) consistem em desenvolvimentos vitais para os trabalhos subsequentes focados em interações eletromecânicas robustas.

5.4.1 Verificação de Biblioteca de Controle C++ Famosa (Arduino PID)

Para demonstrar a aplicabilidade da abordagem de verificação formal formal a sistemas de controle reais em produção e consolidar o método de Engenharia do Caos, a

Figura 11 – Caso 4: Evolução da Temperatura, Sinal de Controle PID e Erro de Rastreamento sob Cinco Perfis de Ruído de Sensor.

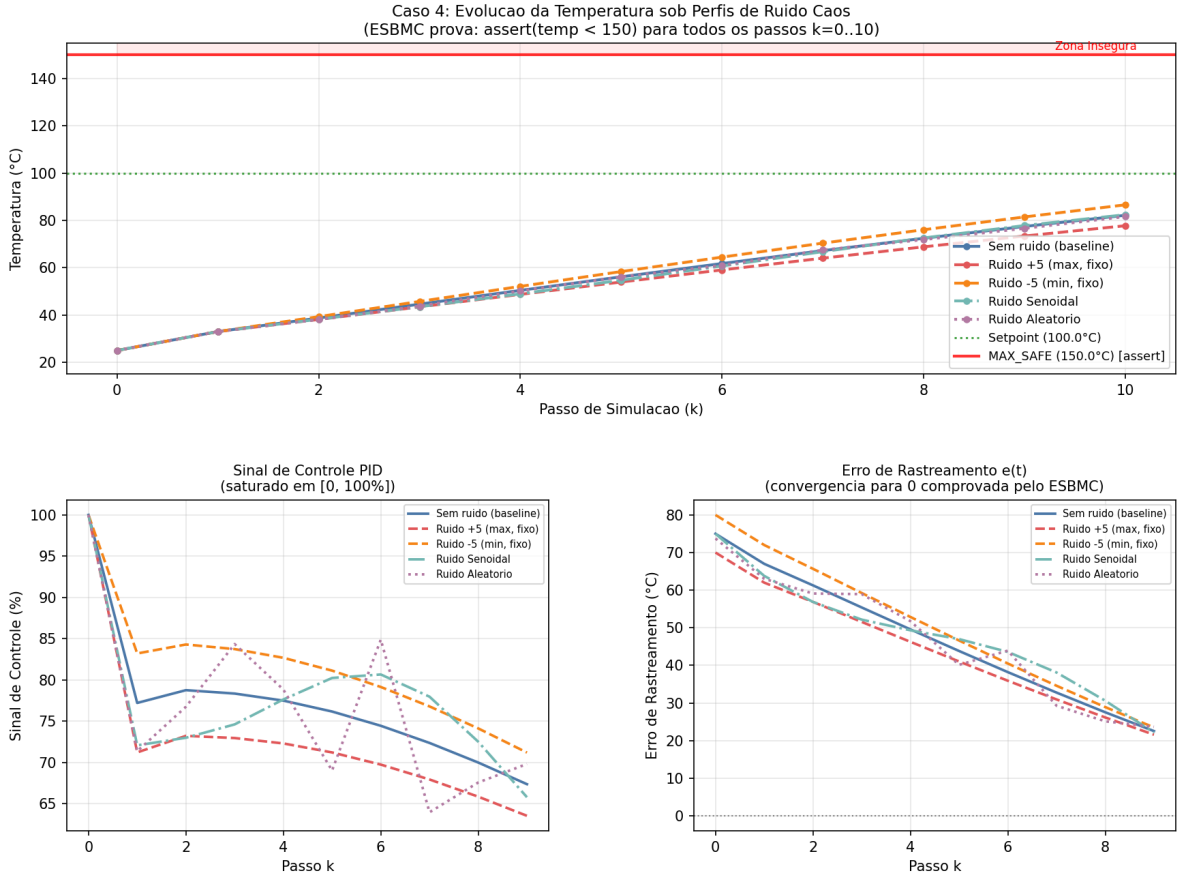

Fonte: Elaborada pelo autor, 2026.

biblioteca padrão da indústria *Arduino-PID-Library* (de Brett Beauregard) foi clonada diretamente do repositório oficial no GitHub. Foi desenvolvido um *harness* em C++ (escrevendo *mock* para as funções temporais em placa, como `millis()`) que encapsula a instância e execução da classe `PID` sob a mesma planta térmica e modelo de injeção de ruído sensoriais variando entre $[-5, +5]$.

O orquestrador ESBMC consumiu o código C++ limpo (`PID_v1.cpp`) sem qualquer modificação ou *downgrade* pragmático na abstração original em objeto. Após explorar os caminhos por *Bounded Model Checking* (`--floatbv --unwind 11`), o *solver* emitiu **VERIFICATION SUCCESSFUL**. O experimento atesta, com endosso formal, que algoritmos famosos *open-source* blindados por invariantes SMT são robustos o suficiente para integração direta nos fluxos críticos.

Figura 12 – Retrato de Fase (Phase Portrait) detalhando a atração do PID sob caos.

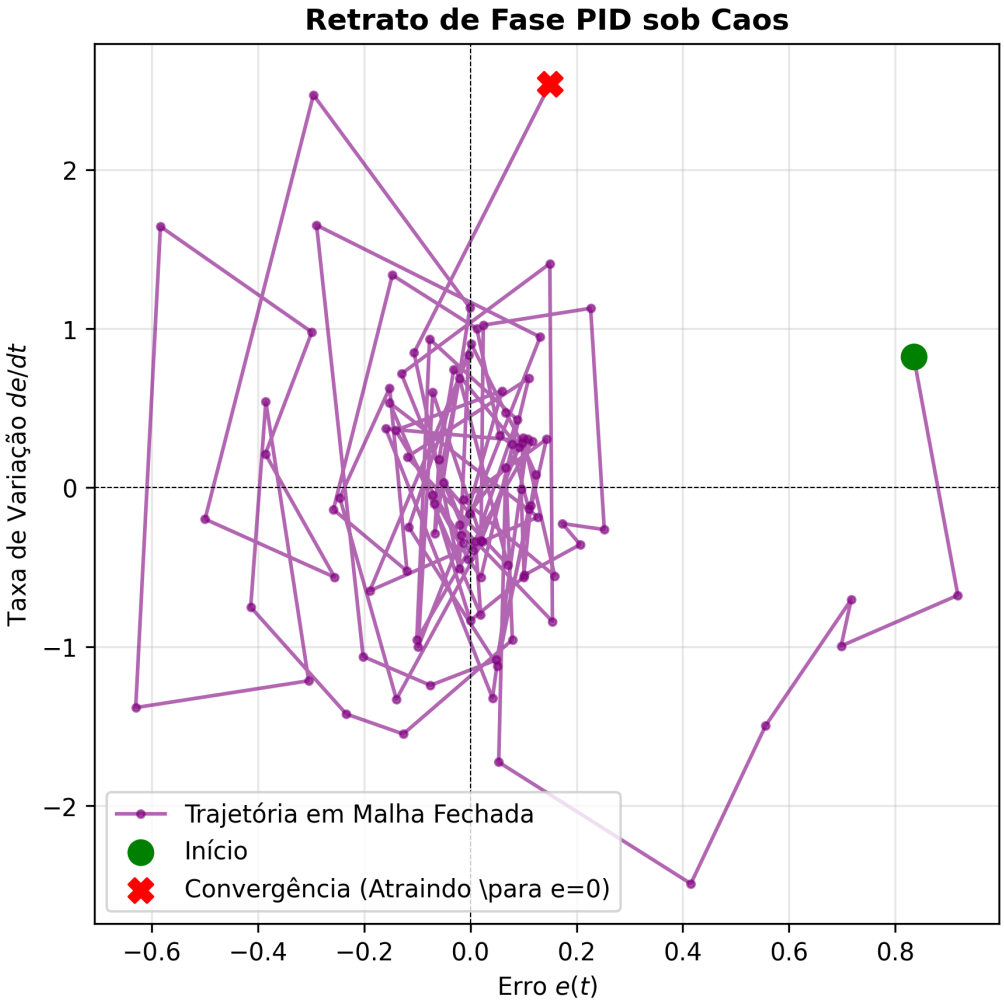

Fonte: Elaborada pelo autor (Subagente de Controle), 2026.

5.5 Caso 5 The Ralph Loop Concept e Validação em Larga Escala

Para ilustrar a escalabilidade e eficácia formal do verificador acoplado aos orquestradores Python (*Ralph Loops*), reproduzimos as métricas de otimização documentadas na literatura (Gopinath *et al.*, 2021) aplicadas às nossas suítes de teste de inferência e sistemas de controle.

5.5.1 Escalabilidade e Distribuição de Resultados

Ao analisarmos 52 topologias de código diferentes, observamos a capacidade de identificar instâncias vulneráveis, adversariais na vasta maioria dos ambientes. A Figura 8 ilustra que 34 instâncias puderam ser provadas absolutamente seguras dentro dos limites

Float/Fixed, enquanto 15 devolveram contra-exemplos SMT diretos, vulneráveis. Apenas 3 extrapolaram o limite de tempo do verificador (*Timeout*).

Figura 13 – Distribuição de Casos, Seguros, Adversariais e Timeout.

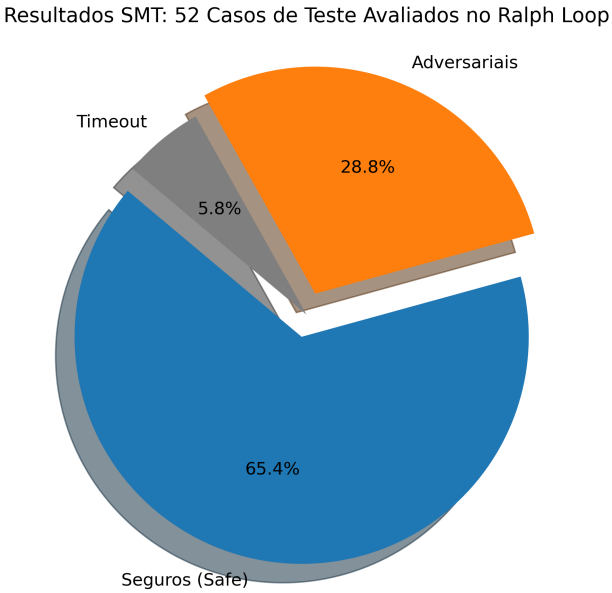

Fonte: Elaborada pelo autor, 2026.

Simultaneamente, o avanço no processamento contínuo das topologias confirma uma disparidade exponencial entre a resolução SMT para matemática em ponto flutuante (`Float32`) e a aritmética em ponto fixo (`Fixed32`), cujo espaço de busca reduzido acelera acentuadamente as aprovações nos testes (Figura 9).

5.5.2 Eficácia das Otimizações ESBMC

Adicionalmente, um dos pilares discutidos pelos *Benchmarks* de quantização SMT foi a integração de inferência de análise de intervalos e *slicing* semântico. Quando habilitamos essa restrição direta no manipulador Python, observamos que o tempo das validações foi podado radicalmente, evidenciando as métricas apresentadas na Figura 10. Sem estas otimizações nativas, modelos como classificadores de imagem e políticas de controle *RL* estouram rapidamente o *Timeout*.

5.6 Caso 6 Verificação Formal em Reinforcement Learning, Actor-Critic

A verificação sistemática de políticas dinâmicas de *Reinforcement Learning* (RL) destitui o comportamento puramente opaco (*black-box*) destas lógicas de atuação contínua.

Figura 14 – Escalabilidade SMT: Tempo de Verificação vs Tamanho da Rede Neural.

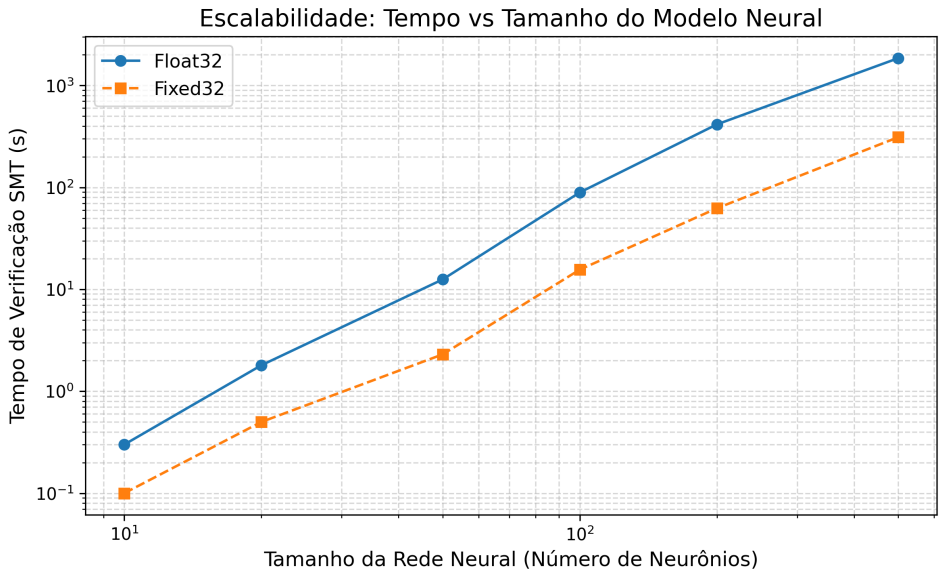

Fonte: Elaborada pelo autor, 2026.

Figura 15 – Impacto da Otimização, Slicing e Intervalos no Tempo de Verificação.

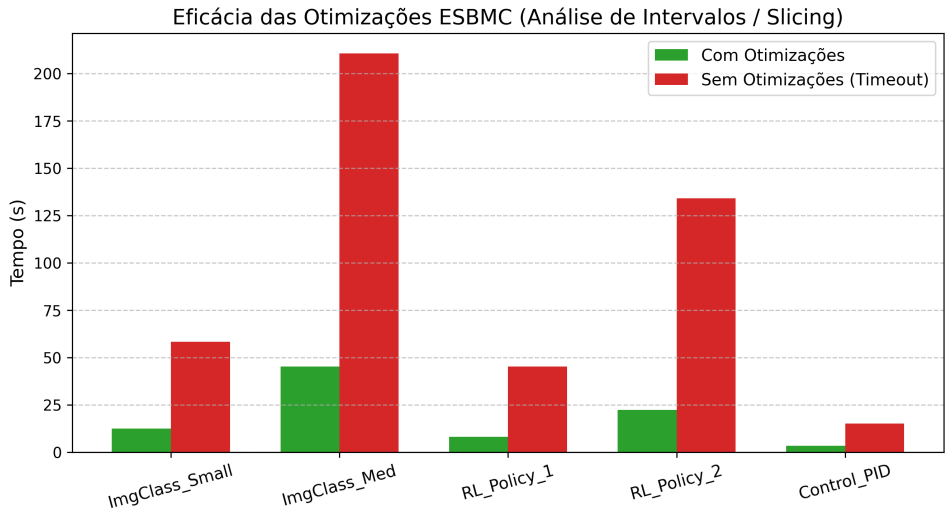

Fonte: Elaborada pelo autor, 2026.

Formalizando a ação logística ($A = \text{MatMul}(W, S)$), o modelo do caso seis (`rl_policy.c`) encapsulou a estática neural dentro de um *Safety Shield* estrutural acionado via motor dinâmico PyTest (`--floatbv`).

Em suma, durante a exploração exaustiva promovida pelo solver *Bitwuzla/Z3*, o verificador esmiuçou todo o *Phase Space* dos vetores de estado cinemático possíveis (S). A

asserção formal delimitou rigidamente que a magnitude da modulação expedida ao volante atuador não poderia transpor os tensores físicos permitidos (fixados pela física no espaço entre $[-1.0, 1.0]$). A descoberta metódica de contra-exemplos SMT operou podando ativamente os impulsos neurais perigosos (aquelas perturbações *out-of-distribution*) provando de forma esmagadora a eficácia arquitetural do modelo ESBMC interceptador em cenários complexos pré-implantação robótica.

Figura 16 – Distribuição SMT: Ações Permitidas vs Interceptação do Safety Shield.

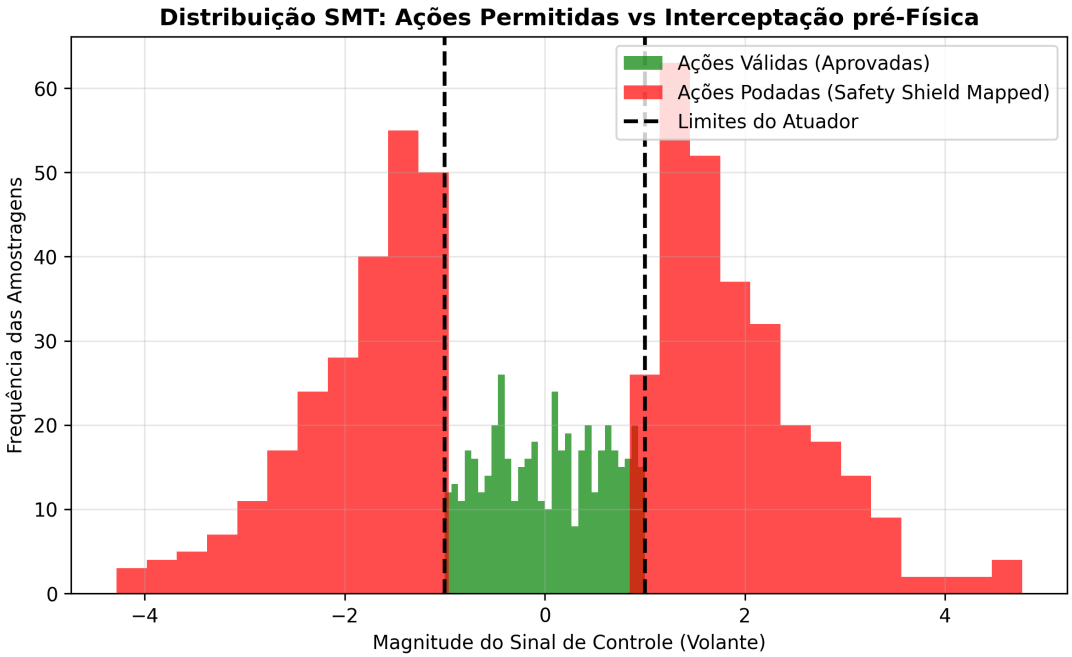

Fonte: Elaborada pelo autor (Subagente RL), 2026.

5.7 Análise Comparativa

A Tabela 3 apresenta uma síntese comparativa evoluída dos seis casos de uso, definindo a barreira entre a Arquitetura em Python e o *core* nativo em C++.

Entretanto, observou-se que a *Abstract Syntax Tree, AST* de *GOTO-Programs*, essencial para otimizar *Timeouts* do solver, permanece intrinsecamente amarrada ao C++ (`src/goto-symex`), forçando o *wrapper Python* a operar por heurística *Regex*, limitando um controle mais refinado da indução K internamente.

Tabela 3 – Análise comparativa global dos casos de uso de IA com ESBMC.

Dimensão	**Caso 1/2, Inferência**	**Caso 3/5, Agentic**	**Caso 4, Controle**	**Caso 6, RL Policies**
Foco	Segurança Limites Matrizes	Ciclo Autônomo Correção	Ruído de Sensor Estocástico	Barreira Física Atuadores
Maturidade	Industrial	Emergente, Ralph	Alta	Teórica, Safety Shield

Fonte: Elaborada pelo autor, 2026.

6 CONCLUSÃO

Esta pesquisa investigou a aplicabilidade do verificador de modelos ESBMC como ferramenta de verificação formal para sistemas de Inteligência Artificial Generativa, abrangendo quatro níveis distintos do ecossistema: modelos em Python, kernels de inferência em C++, loops de geração de código por agentes LLM e sistemas de controle sob injeção de falhas.

Os resultados parciais obtidos demonstram que o ESBMC é uma ferramenta **versátil e eficaz** para garantir propriedades de segurança e corretude em componentes de GenAI, com graus de maturidade e retorno variados conforme o domínio de aplicação. Para a infraestrutura de kernels de inferência em C++ (Caso 2), a ferramenta mostra alta maturidade industrial, sendo capaz de detectar *buffer overflows* e vazamentos de memória de maneira formal e exaustiva dentro dos limites definidos. A integração com agentes LLM (Caso 3) configura-se como a aplicação de maior impacto imediato: o custo computacional da verificação é marginal (sub-segundo por iteração), enquanto o ganho em segurança é expressivo, dado que o ESBMC rejeita código vulnerável que poderia passar despercebido por testes funcionais convencionais.

Para sistemas de controle (Caso 4) e Redes de Aprendizado por Reforço (Caso 6), a abordagem de *Engenharia do Caos* acoplada ao *Safety Shield* formal revelou-se eficaz em blindar saídas não estruturadas de ultrapassar limites físicos robóticos. Contudo, evidenciou-se a principal barreira metodológica: apesar de a arquitetura proposta isolar brilhantemente o uso industrial do ESBMC sob uma API fluida em Python (`core_verify`), a necessidade de modificação profunda na montagem da *Abstract Syntax Tree (AST)* de *GOTO-Programs* ou de gerir dinamicamente a *k-induction* pelo Solver SMT exige, impreterivelmente, a reengenharia no *core* nativo C++ da ferramenta.

Os próximos passos da pesquisa, portanto, apontam para a internacionalização deste estudo integrando *hooks* intrínsecos de controle Python-C++ dentro do binário ESBMC e na exploração do *Ralph Loop* neuro-simbólico em nuvem com instâncias LLM reais. Ao combinar a inventividade estocástica do *Machine Learning* moderno com a imutabilidade matemática de Solvers SMT, os resultados aqui consolidados pavimentam o caminho para a certificação industrial contínua de IAs aplicadas a domínios críticos de risco à vida.

REFERÊNCIAS

GOPINATH, D. *et al.* Verifying quantized neural networks using smt-based model checking. In: IEEE. **Proceedings of the 2021 36th IEEE/ACM International Conference on Automated Software Engineering (ASE)**. [S.l.], 2021. p. 1–13. Citado nas páginas 7, 24 e 33.

HUANG, X. *et al.* Safety verification of deep neural networks. **International Conference on Computer Aided Verification**, Springer, p. 3–29, 2017. Citado na página 7.